

readme

数据说明

20250401-20260630随机抽取了300只股票的逐笔成交数据（股票代码已做混淆处理）

任务要求

- 根据逐笔成交数据降采样日频和分钟频数据（要求有：开盘价、最高价、最低价、收盘价、成交量、成交笔数、成交额、主买量、主卖量、主买额、主卖额等基本指标）
- 开盘价： 第一笔成交价格，对于日频即为当日第一笔成交价格，分钟频即为每分钟第一笔成交价格
 - 最高价： 最大的成交价格，对于日频即为当日最高的成交价格，分钟频即为每分钟最高的成交价格
 - 最低价： 最小的成交价格，对于日频即为当日最低的成交价格，分钟频即为每分钟最低的成交价格
 - 收盘价： 最后一笔成交价格，对于日频即为当日最后一笔成交价格，分钟频即为每分钟最后一笔成交价格

每个字段按如下格式存储（日频每个字段一张表，分钟频每个字段一个文件夹，文件夹内每日一张表）

下图分别为分钟频成交量的表、分钟频收盘价的表、日频成交量的表

分钟频成交量的表

	600705.SH	603282.SH	603059.SH	002124.SZ	605199.SH	000619.SZ	301100.SZ	600358.SH	600088.SH	002691.SZ	...	601038.SH
2026-05-20 09:30:00	66700.0	12100.0	38900.0	300600.0	893914.0	929200.0	101200.0	19000.0	650300.0	37700.0	...	1107600.0
2026-05-20 09:31:00	79200.0	9400.0	39800.0	13300.0	1006720.0	1039000.0	41900.0	35500.0	423500.0	36600.0	...	605200.0
2026-05-20 09:32:00	27700.0	6000.0	7000.0	8700.0	512400.0	586800.0	169300.0	18500.0	420000.0	10800.0	...	393000.0
2026-05-20 09:33:00	37900.0	5300.0	6000.0	91500.0	359200.0	441100.0	93900.0	6800.0	426700.0	24400.0	...	1527300.0
2026-05-20 09:34:00	29800.0	13500.0	99200.0	13100.0	212700.0	419900.0	74200.0	5300.0	528600.0	79900.0	...	585800.0
...	...	...	...	...	...	...	...	...	...	...	...	...
2026-05-20 14:56:00	21100.0	11400.0	100.0	1638100.0	260900.0	168800.0	140300.0	14000.0	298000.0	23900.0	...	54300.0
2026-05-20 14:57:00	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
2026-05-20 14:58:00	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
2026-05-20 14:59:00	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	...	0.0
2026-05-20 15:00:00	46900.0	8200.0	17800.0	1975800.0	180880.0	302300.0	140700.0	23500.0	332114.0	62400.0	...	129900.0

分钟频收盘价的表

	600705.SH	603282.SH	603059.SH	002124.SZ	605199.SH	000619.SZ	301100.SZ	600358.SH	600088.SH	002691.SZ	...	601038.SH
2026-05-20 09:30:00	2613.0	3926.0	359.0	145.0	4935.0	2214.0	788.0	3583.0	2168.0	1320.0	...	611.0
2026-05-20 09:31:00	2597.0	3934.0	358.0	145.0	4800.0	2150.0	786.0	3571.0	2163.0	1316.0	...	605.0
2026-05-20 09:32:00	2603.0	3940.0	359.0	145.0	4791.0	2137.0	788.0	3578.0	2159.0	1314.0	...	610.0
2026-05-20 09:33:00	2614.0	3946.0	358.0	145.0	4823.0	2189.0	789.0	3584.0	2151.0	1313.0	...	613.0
2026-05-20 09:34:00	2605.0	3939.0	359.0	145.0	4868.0	2193.0	786.0	3580.0	2142.0	1305.0	...	608.0
...	...	...	...	...	...	...	...	...	...	...	...	...
2026-05-20 14:56:00	2588.0	3937.0	354.0	145.0	4945.0	2098.0	782.0	3515.0	2144.0	1290.0	...	591.0
2026-05-20 14:57:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN
2026-05-20 14:58:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN
2026-05-20 14:59:00	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN
2026-05-20 15:00:00	2585.0	3923.0	354.0	145.0	4946.0	2093.0	782.0	3513.0	2144.0	1290.0	...	590.0

日频成交量的表

	600705.SH	603282.SH	603059.SH	002124.SZ	605199.SH	000619.SZ	301100.SZ	600358.SH
2025-04-01	1451500.0	3914200.0	8320232.0	141334037.0	1727200.0	2455100.0	15567574.0	2388393.0
2025-04-02	2170700.0	5345576.0	7351698.0	93605318.0	1441380.0	1566027.0	11841400.0	2063900.0
2025-04-03	1656800.0	5160615.0	10191477.0	73133810.0	1569660.0	2345800.0	27186900.0	4454596.0
2025-04-07	1641300.0	4174265.0	2218700.0	35568307.0	4329300.0	1932600.0	21977000.0	8868020.0
2025-04-08	2455570.0	3312000.0	9959300.0	80928557.0	3240854.0	6052200.0	25264990.0	7861200.0
...	...	...	...	...	...	...	...	...
2026-06-24	1616900.0	1190899.0	6865118.0	88325960.0	20364160.0	4349924.0	23152633.0	1133400.0
2026-06-25	1612111.0	1067592.0	7362425.0	60410843.0	22043617.0	5088478.0	29096544.0	1242300.0
2026-06-26	1275000.0	1622562.0	7502320.0	37531561.0	14839031.0	5174976.0	17835800.0	1096704.0
2026-06-29	1667600.0	996400.0	2101500.0	49968117.0	16556540.0	5215800.0	27056200.0	1745720.0
2026-06-30	1661600.0	1079001.0	1081000.0	27054870.0	15002995.0	5418900.0	35416357.0	1157600.0

2. 基于所给的数据进行因子构建
- 示例因子逻辑：[1, 5, 10, 20]日成交额均值的标准差的对数
3. 因子评价

- 因子分层效果
- 计算ic, ir, icir, rank_ic, rank_ir, rank_icir等指标
- 基于上述数据另构建1至3个因子，并测试效果

4. 拓展1

- 假设初始资金1kW, 每天使用当日各因子值与次日收益率计算的ic对因子进行加权产生信号选取最优的10只构造组合，采用收盘价调仓，设卖出手续费万5，买入手续费不计，计算该策略的净值收益曲线并分析波动率，最大回撤，夏普率等
 - 采用次日开盘价调仓重复上述策略回测及分析
 - 使用当日各因子值与次日收益率计算的ic对因子进行加权产生信号选取最优的10只来构建投资组合有何问题？该如何修改？

5. 拓展2

- 基于降采样后的分钟线数据，设计端到端的神经网络模型（如LSTM），用于预测下一个分钟股价的涨跌。

说明

1. 交易时间9:15:00-9:25:00为开盘集合竞价时间，14:57:00-14:59:59为尾盘集合竞价，集合竞价的订单会以统一的价格成交
2. 连续竞价阶段9:30:00-11:30:00, 13:00:00-14:57:00
3. 日频价格数据填充规则：日频（高开低收）价 用前1日收盘价填充
4. 分钟频价格数据填充规则：连续竞价阶段（高开低收）价 用前1分钟收盘价填充
5. BSFlag 买卖标志为预处理过的字段，处理规则：根据成交双方的委托id大小（时间先后），大的为主动单，主动单是一笔买单，则为主动买成交
6. 数据大小考虑，数据中的Price字段乘了100化为整形

逐笔成交字段说明

字段名	注释	数据类型
Time	成交时间	int
Price	成交价格	int
Volume	成交量	int
BSFlag	买卖标志（0：主买成交，1：主卖成交，2：集合竞价成交）	int

下图所示的原始逐笔成交数据中含BuyOrderID、SellOrderID字段，已作如下处理：
BuyOrderID、SellOrderID分别为一笔委托订单，该id在同一天（15:00:00收盘前）的一只票中随时间严格递增，二者id更大的是后出现的订单，是主动单。如BuyOrderID > SellOrderID,

为主动买单，BSFlag 为0,以此类推。

Symbol	TradingDate	TradingTime	BuyOrderID	SellOrderID	TradePrice	TradeVolume
1	20260701	2026-07-01 09:40:31.430	9627514	9658346	10.06	500